

Distribuição de Frequências

Tabelas · Histogramas · Boxplots · Titanic Dataset

fi

Frequência Absoluta

Contagem direta de ocorrências

fri

Frequência Relativa

Proporção em relação ao total (%)

Fi

Frequência Acumulada

Soma progressiva das frequências

Dataset utilizado

Titanic — Machine Learning from Disaster

kaggle.com/competitions/titanic/data · train.csv · 891 passageiros · 12 variáveis

Pré-requisito: os 4 tipos de variável (Nominal · Ordinal · Discreta · Contínua) — ver material de apoio de Tipos de Variáveis

Os 3 tipos de frequência

Uma distribuição de frequências organiza os dados em categorias ou intervalos e mostra quantas vezes cada valor aparece. É o ponto de partida da análise descritiva.

fi — Frequência Absoluta

Contagem direta de quantas vezes cada valor aparece no dataset.

Pergunta: quantas vezes esse valor aparece?

Exemplo Titanic: 3ª classe: 491 passageiros

fi = contagem de ocorrências

Conta o numero bruto de ocorrencias — independente do total da amostra.

fri — Frequência Relativa

Proporção de cada valor em relação ao total, geralmente expressa em porcentagem.

Pergunta: que % do total isso representa?

Exemplo Titanic: 3ª classe: 55,11% dos passageiros

fri = (fi / n) x 100

Divide a contagem pelo total e multiplica por 100 — permite comparar datasets de tamanhos diferentes.

Fi — Frequência Acumulada

Soma progressiva das frequências absolutas. Responde: quantos estão até este ponto?

Pergunta: quantos estão abaixo deste valor?

Exemplo Titanic: Até 2ª classe: 400 passageiros (44,89%)

Fi = f1 + f2 + ... + fi

Soma progressiva — util para responder 'quantos estao abaixo de determinado valor?'

Pclass

Classe do bilhete — Qualitativa Ordinal

Definição

Para variáveis categóricas, cada valor é uma categoria. Listamos cada uma e contamos quantas vezes aparece — sem precisar criar intervalos.

Teste rápido:

A 1a classe é 'maior' que a 3a? -> SIM (tem ordem). Pclass é ordinal.

Se não tivesse ordem (ex: cor do carro), seria nominal.

Tabela de frequências — Pclass

Classe	Freq. Absoluta (fi)	Freq. Relativa (%)	Freq. Acumulada (Fi)
1ª classe	216	24,24%	216
2ª classe	184	20,65%	400
3ª classe	491	55,11%	891
TOTAL	891	100,00%	—

Como ler a tabela

- 491 passageiros viajavam na 3a classe — mais da metade do navio (55,11%)
- A freq. acumulada da 2a classe é 400: 44,89% dos passageiros viajavam nas classes 1 e 2
- A coluna acumulada responde: 'quantos passageiros viajavam até a Xa classe?'

Código Python

```
# Frequência absoluta
freq_abs = df['Pclass'].value_counts().sort_index()

# Frequência relativa (%)
freq_rel = freq_abs / freq_abs.sum() * 100

# Frequência acumulada
freq_acum = freq_abs.cumsum()
```

Outras variáveis categóricas no Titanic

Embarked

Porto: C · Q · S

Survived

0 = não · 1 = sim

Sex

male · female

Age

Idade dos passageiros — Quantitativa Contínua

Por que precisamos de intervalos?

Para variáveis contínuas, cada valor pode ser diferente (7,5 · 25,0 · 31,3 anos...).

Listar cada valor seria inútil. A solução é agrupar em faixas com `pd.cut()`.

Esse agrupamento é exatamente o que o histograma faz visualmente.

Atenção — valores ausentes:

Age tem 177 valores nulos. O `pd.cut()` os ignora. Os % são calculados sobre os 714 com idade registrada.

Tabela de frequências por faixas — Age

Faixa etária	Intervalo	Freq. Absoluta	Freq. Relativa (%)	Freq. Acumulada
Criança	0 – 12	69	9,66%	69
Adolescente	13 – 18	55	7,70%	124
Adulto jovem	19 – 35	306	42,86%	430
Adulto	36 – 60	249	34,87%	679
Idoso	61 – 100	35	4,90%	714
TOTAL	—	714	100,00%	—

Código Python — `pd.cut()`

```
df['faixa_etaria'] = pd.cut(
    df['Age'],
    bins=[0, 12, 18, 35, 60, 100],
    labels=['Crianca', 'Adolescente',
            'Adulto jovem', 'Adulto', 'Idoso']
)

freq = df['faixa_etaria'].value_counts().sort_index()
```

Como escolher as faixas?

- Use o contexto do problema — faixas etárias, faixas de renda etc.
- Cada faixa deve ter sentido prático para quem vai ler a tabela
- Regra geral: entre 5 e 10 faixas costuma ser suficiente

Outras variáveis quantitativas no Titanic

Fare

Tarifa paga (£)

SibSp

Irmãos/conjuges

Parch

Pais/filhos


Histograma

Representação gráfica da distribuição de frequências por intervalos


Cada barra representa um intervalo de valores. A altura da barra mostra quantos dados caem naquele intervalo. Usado para variáveis numéricas contínuas.

Diferente do gráfico de barras: as barras ficam coladas porque os intervalos são contínuos.

Age — distribuição aproximadamente simétrica



Fare — assimetria positiva (cauda à direita)



Simétrica

Média e mediana próximas. Distribuição equilibrada dos dois lados.

Assimétrica positiva

Cauda à direita. Maioria concentrada à esquerda. Média > mediana.

Assimétrica negativa

Cauda à esquerda. Maioria concentrada à direita. Média < mediana.

O parametro bins — como ele afeta a leitura

bins=5 Muito grosso — perde detalhes reais da distribuição

bins=20 Equilibrado — bom ponto de partida para a maioria

bins=50 Muito fino — ruído começa a esconder o padrão

Regra prática: bins aprox. raiz(n), onde n = numero de dados

Codigo Python


```
plt.hist(df['Age'].dropna(), bins=20, color='steelblue', edgecolor='white')
plt.title('Distribuicao de Idade')
plt.xlabel('Idade') # rotulo do eixo X
plt.ylabel('Frequencia') # rotulo do eixo Y
plt.tight_layout()
plt.show()
```

Boxplot

Resumo em 5 números e identificação de outliers

O boxplot resume a distribuição em 5 números e destaca outliers automaticamente. É especialmente útil para comparar a distribuição entre diferentes grupos.

Anatomia do boxplot



Resumo dos 5 números — Age (Titanic)

Mínimo	Q1 (25%)	Mediana	Q3 (75%)	Máximo
0,42 anos	20 anos	28 anos	38 anos	80 anos

Boxplot comparativo — o verdadeiro poder

Medianas

As linhas centrais estão no mesmo nível? Algum grupo tem valores maiores?

Tamanho das caixas (IQR)

Caixa maior = maior variabilidade. Qual classe é mais homogênea?

Outliers

Quantos pontos aparecem fora dos bigodes em cada grupo?

Código Python

```
# Boxplot simples
sns.boxplot(y=df['Age'], color='lightblue')

# Boxplot comparativo por grupo
sns.boxplot(x='Pclass', y='Age', data=df, palette='Set2')

# Resumo dos 5 números
q1, q2, q3 = df['Age'].quantile([0.25, 0.5, 0.75])
```

Guia rápido de funções Python

Frequencia absoluta

```
df['col'].value_counts()
```

Frequencia relativa

```
df['col'].value_counts(normalize=True)
```

Criar intervalos

```
pd.cut(df['col'], bins=[...], labels=[...])
```

Frequencia acumulada

```
freq_abs.cumsum()
```

Resumo estatístico

```
df[['col1', 'col2']].describe()
```

Media / Mediana

```
df['col'].mean() / df['col'].median()
```

Desvio padrao

```
df['col'].std()
```

Quartis

```
df['col'].quantile(0.25)
```

Histograma

```
plt.hist(df['col'], bins=20, edgecolor='white')
```

Boxplot simples

```
sns.boxplot(y=df['col'])
```

Boxplot comparativo

```
sns.boxplot(x='grupo', y='col', data=df)
```

Assimetria

```
df['col'].skew()
```

Curtose

```
df['col'].kurtosis()
```

Dica: análise visual e numerica se complementam

Calcule os números primeiro (.describe(), .skew()), depois confirme visualmente com histograma e boxplot.